

Contents

1 Lecture 04: 使用卷积神经网络进行图像分类	1
1.1 Image Classification with Convolutional Neural Networks 结构化知识详稿	1
1.2 0. 一次完整 CNN 训练闭环	1
1.2.1 一句话核心	1
1.2.2 示例网络	1
1.2.3 关键对象区分	2
1.3 1. 从全连接网络到 CNN	2
1.4 2. 卷积层：局部模板匹配	3
1.5 3. 参数共享与多个卷积核	3
1.6 4. 初始化与特征学习	3
1.7 5. 卷积核尺寸、内积与输出尺寸	3
1.8 6. ReLU、池化与下采样	4
1.9 7. 多层卷积如何协同	4
1.10 8. 全连接、Softmax 与 loss	5
1.11 9. 反向传播与 AdamW	5
1.12 10. 本讲最重要的闭环	5
1.13 11. 常见误区	5
1.14 12. 自测问题	6
1.15 一句话收束	6

1 Lecture 04: 使用卷积神经网络进行图像分类

1.1 Image Classification with Convolutional Neural Networks | 结构化知识详稿

整理自 CS231n 第 4 课视频字幕、课件，以及学习过程中的连续追问。本文先用一次完整 CNN 训练闭环串起全部知识，再拆解关键概念。

1.2 0. 一次完整 CNN 训练闭环

1.2.1 一句话核心

CNN 的所有卷积核和全连接权重在模型建立时一次性初始化；前向传播中，各层处理上一层产生的特征图并得到 loss；反向传播中，loss 沿原路径反向计算所有参数的梯度，优化器统一更新它们。

1.2.2 示例网络

输入 $3 \times 32 \times 32$

→ Conv1: 6 个 $3 \times 5 \times 5$ 卷积核, stride=1, padding=0

→ ReLU

→ MaxPool: 2×2 , stride=2

→ Conv2: 10 个 $6 \times 5 \times 5$ 卷积核, stride=1, padding=0

→ ReLU

→ MaxPool: 2×2 , stride=2

→ Flatten

→ Fully Connected: $250 \rightarrow 10$

→ Softmax Cross-Entropy Loss

模型建立时一次性初始化：

$$W_1 \in \mathbb{R}^{6 \times 3 \times 5 \times 5}, \quad W_2 \in \mathbb{R}^{10 \times 6 \times 5 \times 5}, \quad W_3 \in \mathbb{R}^{10 \times 250}$$

前向传播：

$$3 \times 32 \times 32 \rightarrow 6 \times 28 \times 28 \rightarrow 6 \times 14 \times 14 \rightarrow 10 \times 10 \times 10 \rightarrow 10 \times 5 \times 5 \rightarrow 250 \rightarrow 10$$

$$Z_1 = W_1 * X + b_1, \quad A_1 = \text{ReLU}(Z_1), \quad P_1 = \text{Pool}(A_1)$$

$$Z_2 = W_2 * P_1 + b_2, \quad A_2 = \text{ReLU}(Z_2), \quad P_2 = \text{Pool}(A_2)$$

$$h = \text{Flatten}(P_2), \quad s = W_3 h + b_3$$

$$p_j = \frac{e^{s_j}}{\sum_k e^{s_k}}, \quad L_i = -\log p_y$$

反向传播：

L → logits → W3 / h → P2 → Pool2 → ReLU2 → W2 / P1
→ Pool1 → ReLU1 → W1

得到：

$$\frac{\partial L}{\partial W_3}, \quad \frac{\partial L}{\partial W_2}, \quad \frac{\partial L}{\partial W_1}$$

下一批继续使用更新后的参数，而不是重新初始化。

1.2.3 关键对象区分

对象	本质	生命周期
卷积核 / 权重	模型参数	初始化一次，训练中持续更新和保留
偏置	模型参数	初始化一次，训练中持续更新和保留
特征图	当前输入的中间数据	每次 forward 重新计算
梯度	loss 对变量的敏感度	每次 backward 重新计算
优化器状态	动量、一阶/二阶矩	跨训练步骤保存

1.3 1. 从全连接网络到 CNN

全连接层将图像展平：

$$X \in \mathbb{R}^{3 \times H \times W} \rightarrow x \in \mathbb{R}^{3HW}$$

然后：

$$h = \phi(Wx + b)$$

数值未消失，但模型结构没有显式利用二维邻接关系和位置共享。CNN 的核心改造是：保留空间结构，只让神经元读取局部区域，并在所有位置复用同一检测器。

1.4 2. 卷积层：局部模板匹配

某个位置：

$$y_{k,i,j} = \sum_{c,u,v} W_{k,c,u,v} X_{c,i+u,j+v} + b_k$$

卷积核是可学习参数，输入图像块是数据。二者逐元素相乘求和，得到一个局部匹配响应。

一个卷积核在所有空间位置计算后产生一张特征图；多个卷积核产生多张特征图。

1.5 3. 参数共享与多个卷积核

同一卷积核跨位置共享参数：

左上角使用 K1

中央使用 K1

右下角仍使用 K1

不同卷积核之间则通常不同：

K1：可能偏向竖直边缘

K2：可能偏向水平边缘

K3：可能偏向颜色对比

多个卷积核可以读取同一片输入数据，从不同角度描述同一区域。

1.6 4. 初始化与特征学习

卷积核通常使用 Xavier、He 等受控随机初始化。随机初始化的作用是打破对称性，而不是规定某个卷积核必须学成某种特征。

若参数和后续结构完全对称：

相同参数 → 相同输出 → 相同梯度 → 相同更新

最终特征由初始化、数据、任务、网络结构、损失和优化共同决定。同一初始化在不同数据集上完全可能分别学成竖直边缘、水平边缘或其他模式。

1.7 5. 卷积核尺寸、内积与输出尺寸

方正的是观察窗口，不是特征本身。 3×3 窗口内部可以学习水平、竖直、斜向或不规则局部模式。

输出尺寸：

$$H_{\text{out}} = \left\lfloor \frac{H - K_H + 2P_H}{S_H} \right\rfloor + 1$$
$$W_{\text{out}} = \left\lfloor \frac{W - K_W + 2P_W}{S_W} \right\rfloor + 1$$

同尺寸填充 (stride=1, 奇数核)：

$$P_H = \frac{K_H - 1}{2}, \quad P_W = \frac{K_W - 1}{2}$$

卷积核数量决定输出通道，卷积核高宽 / stride / padding 决定输出高宽。

1.8 6. ReLU、池化与下采样

卷积是线性的，所以层间需要 ReLU：

$$\text{ReLU}(x) = \max(0, x)$$

池化把局部区域的多个数汇总成一个代表值：

$$y = \max(x_1, \dots, x_n)$$

或：

$$y = \frac{1}{n} \sum_i x_i$$

池化输出尺寸：

$$H_{\text{out}} = \left\lfloor \frac{H - K_H}{S_H} \right\rfloor + 1$$

$$W_{\text{out}} = \left\lfloor \frac{W - K_W}{S_W} \right\rfloor + 1$$

下采样不是优化器，而是空间压缩：减少计算、扩大有效感受野，并牺牲部分精细位置。

1.9 7. 多层卷积如何协同

第一层：

原始像素 → 边缘 / 颜色 / 简单纹理

第二层：

第一层多个通道 → 曲线 / 角点 / 更复杂纹理

更深层：

局部结构 → 物体部件 → 语义特征

所有层从训练开始就共同学习，不是先训练完第一层再创建第二层。

1.10 8. 全连接、Softmax 与 loss

$$P_2 \in \mathbb{R}^{10 \times 5 \times 5} \rightarrow h \in \mathbb{R}^{250}$$

$$s = W_3 h + b_3 \in \mathbb{R}^{10}$$

$$p_j = \frac{e^{s_j}}{\sum_k e^{s_k}}$$

$$L_i = -\log p_y$$

卷积层负责提供特征，全连接层负责综合特征形成类别证据，loss 统一评价整个系统。

1.11 9. 反向传播与 AdamW

反向传播负责：

$$abla_{W_1} L, \quad \nabla_{W_2} L, \quad \nabla_{W_3} L$$

优化器负责更新：

$$W \leftarrow W - \eta \nabla_W L$$

AdamW 使用梯度的一阶、二阶移动平均，并解耦权重衰减。但它不替代 forward、loss 或 backward，只替代最后的参数更新规则。

1.12 10. 本讲最重要的闭环

卷积核 = 持久存在的可学习参数

特征图 = 针对当前输入临时生成的数据

所有层参数一次性初始化

→ 每层使用自己的参数做 forward

→ 最终得到 logits 和 loss

→ backward 为所有层计算梯度

→ optimizer 更新所有参数

→ 下一批继续使用更新后的参数

1.13 11. 常见误区

1. 卷积核是从图片中切出来的。——卷积核是参数，图像块是数据。
2. 第二层运行到时才初始化。——所有层在模型创建时就已初始化。
3. 第一层做完后被丢弃。——它每次处理原图，其输出供后层使用，并持续被 loss 更新。
4. 池化产生新卷积核。——池化产生下采样后的特征图。
5. 参数共享表示所有卷积核一样。——共享发生在同一核的不同位置。
6. 随机初始化保证不同特征。——只打破对称性，不保证严格分工。

7. 下采样是优化参数。——下采样压缩空间，优化器才更新参数。
 8. Softmax 就是 loss。——Softmax 生成概率，交叉熵生成 loss。
 9. AdamW 替代反向传播。——backward 算梯度，AdamW 用梯度更新参数。
-

1.14 12. 自测问题

1. 为什么 $3 \times 5 \times 5$ 卷积核在一个位置只输出一个数？
 2. 为什么 6 个卷积核输出 6 张特征图，而不是把原图切成 6 块？
 3. 为什么第二层卷积核必须覆盖前一层全部 6 个通道？
 4. 参数共享与不同卷积核完全相同有什么区别？
 5. 为什么池化通常不改变通道数？
 6. 为什么所有层可以同时从随机状态开始训练？
 7. Softmax 和交叉熵各自负责什么？
 8. `loss.backward()` 与 `optimizer.step()` 分别做什么？
-

1.15 一句话收束

卷积神经网络不是一层层临时制造卷积核，而是用一组从训练开始就存在的参数化操作，把原始像素逐层转换为更高级特征；最终分类损失再沿整个计算图反向更新所有层，使特征提取和类别判断共同完成。