

Lecture 05: CNN 架构与训练

Training CNNs and CNN Architectures | 结构化知识详稿

CS231n 自学笔记

2026-07-16

Contents

1	0. 一次完整实践闭环	2
2	1. CNN 中不同模块的职责与位置	3
2.1	1.1 一条典型 CNN 流程	3
2.2	1.2 为什么是 Conv → Norm → ReLU	3
3	2. 归一化层	3
3.1	2.1 统一公式	3
3.2	2.2 不同归一化方法的核心区别	4
4	3. 输入图像标准化	4
4.1	3.1 这些统计量属于什么	4
4.2	3.2 为什么验证和测试必须沿用训练集统计量	4
5	4. Dropout	5
5.1	4.1 为什么训练时随机丢弃特征	5
5.2	4.2 数学形式	5
5.3	4.3 传统 Dropout 与 Inverted Dropout	5
5.4	4.4 数值例子	6
5.5	4.5 反向传播	6
6	5. 激活函数	6
6.1	5.1 为什么线性层之间必须有非线性	6
6.2	5.2 Sigmoid、ReLU、GELU	7
7	6. VGG 与小卷积核	7
7.1	6.1 感受野	7
7.2	6.2 参数量与表达能力	7
8	7. ResNet 与残差连接	7
8.1	7.1 为什么深层普通网络会退化	7
8.2	7.2 残差学习	8
8.3	7.3 它和 CNN 的关系	8
9	8. 多个残差块与 F_1, F_2	8
10	9. 为什么形状保持 $64 \times 56 \times 56$	9
11	10. 通道数变化与投影捷径	9
11.1	10.1 主分支	9
11.2	10.2 捷径分支	9
11.3	10.3 1×1 卷积如何改变通道数	10
12	11. 同一层神经元与参数共享	10

12.1 11.1 全连接层	10
12.2 11.2 CNN 中的两个层次	10
13 12. Kaiming 初始化	10
14 13. 权重衰减	11
14.1 13.1 更新公式	11
14.2 13.2 L2 正则化视角	11
14.3 13.3 AdamW	11
15 14. 权重衰减与重要特征	11
15.1 14.1 权重大小不等于特征重要性	12
16 15. 数据增强	12
17 16. 迁移学习	12
17.1 16.1 数据少、领域相似	12
17.2 16.2 数据较多、领域相似	12
17.3 16.3 领域差异大	13
18 17. 训练调试	13
18.1 17.1 先过拟合一个小样本	13
18.2 17.2 训练/验证曲线	13
18.3 17.3 随机搜索	13
19 18. 本讲最重要的闭环	13
20 19. 常见误区	13
21 20. 自测问题	14
22 一句话收束	14

1 0. 一次完整实践闭环

本讲可以围绕一个实际任务串起来：训练一个猫、狗、鸟、汽车四分类 CNN。

训练图片

- 仅使用训练集计算 RGB 均值与标准差
- 随机裁剪、翻转、颜色扰动
- Conv / Norm / Activation 搭建特征提取主干
- 使用 VGG 式小卷积堆叠或 ResNet 残差块
- Global Pool / FC 输出 logits
- Softmax Cross-Entropy 得到任务损失
- 加入权重衰减等正则化
- backward 计算所有参数梯度
- SGD / AdamW 更新参数
- 用固定预处理统计量验证
- 数据不足时使用迁移学习

这里所有知识都围绕两个目标：

1. **让深层网络可优化**：激活函数、归一化、Kaiming 初始化、残差连接。
2. **让模型可泛化**：Dropout、权重衰减、数据增强、迁移学习与验证集调参。

2 1. CNN 中不同模块的职责与位置

2.1 1.1 一条典型 CNN 流程

Input

→ Conv
→ Normalization
→ ReLU
→ Pool / Strided Conv
→ ...
→ Global Average Pooling
→ FC
→ ReLU
→ Dropout
→ FC
→ logits

这不是唯一正确顺序，但它清楚体现了分工：

模块	主要作用	常见位置
Conv / FC	线性变换，生成新特征	每个特征变换阶段
Normalization	稳定激活尺度	线性层后、激活前最常见
ReLU / GELU	引入非线性	线性算子之后
Pool / stride	降低空间分辨率	若干卷积之后
Dropout	训练时随机屏蔽特征	激活后、下一层前，常见于分类头
Residual Connection	保留输入并改善深层优化	跨过若干卷积层

2.2 1.2 为什么是 Conv → Norm → ReLU

卷积先产生：

$$z = W * x + b$$

不同通道的 z 可能具有不同均值和尺度。归一化随后执行：

$$\hat{z} = \frac{z - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

再由：

$$y = \gamma \hat{z} + \beta$$

学习需要的尺度与中心，最后交给 ReLU：

$$\text{ReLU}(y) = \max(0, y)$$

直觉上：卷积“生产特征”，归一化“整理特征”，激活函数“加入非线性判断”。

3 2. 归一化层

3.1 2.1 统一公式

所有常见归一化层都有类似结构：

$$\hat{x} = \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}}, \quad y = \gamma \hat{x} + \beta$$

- μ : 均值。
- σ^2 : 方差。
- ε : 避免分母为 0。
- γ : 可学习缩放参数。
- β : 可学习平移参数。

归一化并不是把特征永久限制为均值 0、标准差 1。 γ 与 β 允许模型重新选择合适分布。

3.2 2.2 不同归一化方法的核心区别

对于：

$$X \in \mathbb{R}^{N \times C \times H \times W}$$

方法	统计范围	是否依赖其他样本
BatchNorm	每个通道跨 N, H, W	是
LayerNorm	每个样本跨 C, H, W	否
InstanceNorm	每个样本、每个通道跨 H, W	否
GroupNorm	每个样本、每组通道跨 C_g, H, W	否

它们不是在做四种完全不同的数学操作，而是在选择不同的元素集合来计算统计量。

4 3. 输入图像标准化

图像预处理发生在网络之前。对 RGB 三通道分别计算训练集统计量：

$$\mu_R, \mu_G, \mu_B, \quad \sigma_R, \sigma_G, \sigma_B$$

并处理所有输入：

$$\hat{x}_{i,j,c} = \frac{x_{i,j,c} - \mu_{c,\text{train}}}{\sigma_{c,\text{train}}}$$

4.1 3.1 这些统计量属于什么

它们更准确地叫：

- 训练集统计量；
- 预处理参数；
- 数据预处理阶段拟合出的状态。

它们不是卷积核那样由反向传播学习的模型参数，也不是学习率那样由人搜索的典型超参数。

4.2 3.2 为什么验证和测试必须沿用训练集统计量

训练阶段模型适应的是：

$$T_{\text{train}}(x) = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

如果验证时改用：

$$T_{\text{val}}(x) = \frac{x - \mu_{\text{val}}}{\sigma_{\text{val}}}$$

相同原始像素在两个阶段会具有不同数值含义，相当于训练和考试使用不同刻度尺。同时，提前利用完整验证或测试分布也会造成数据泄漏。

正确流程：

训练集 → 计算 $\mu_{\text{train}}, \sigma_{\text{train}}$

训练集 → 使用 $\mu_{\text{train}}, \sigma_{\text{train}}$

验证集 → 使用 $\mu_{\text{train}}, \sigma_{\text{train}}$

测试集 → 使用 $\mu_{\text{train}}, \sigma_{\text{train}}$

部署新样本 → 使用 $\mu_{\text{train}}, \sigma_{\text{train}}$

5 4. Dropout

5.1 4.1 为什么训练时随机丢弃特征

假设模型判断猫时使用：耳朵、尾巴、毛发和爪子。若训练集中“耳朵 + 毛发”总是一起出现，模型可能过度依赖这个固定组合。

Dropout 每次随机让部分激活变为 0，使模型必须形成冗余表示：即使某些证据暂时缺失，也能利用其他证据完成判断。

5.2 4.2 数学形式

设保留概率为 q ：

$$m_i \sim \text{Bernoulli}(q)$$

原始激活 h_i 被处理为：

$$\tilde{h}_i = m_i h_i$$

若不缩放：

$$\mathbb{E}[\tilde{h}_i] = q h_i$$

训练时的平均激活会缩小为原来的 q 倍。

5.3 4.3 传统 Dropout 与 Inverted Dropout

传统写法：

训练时：随机丢弃，不缩放

测试时：使用全部激活，并乘 q

现代框架常用 inverted dropout：

训练时：

$$\tilde{h} = \frac{m \odot h}{q}$$

测试时：

$$\tilde{h} = h$$

因为：

$$\mathbb{E} \left[\frac{m_i h_i}{q} \right] = h_i$$

所以训练与测试的激活期望一致。

5.4 4.4 数值例子

设：

$$h = [4, 6], \quad q = 0.5$$

训练时可能得到：

- 两个都保留： $[8, 12]$ ；
- 只保留第一个： $[8, 0]$ ；
- 只保留第二个： $[0, 12]$ ；
- 全部丢弃： $[0, 0]$ 。

四种和分别为：

$$20, 8, 12, 0$$

平均值：

$$\frac{20 + 8 + 12 + 0}{4} = 10$$

测试时：

$$4 + 6 = 10$$

两阶段期望一致。

5.5 4.5 反向传播

某激活在本次前向传播中被置零，则该路径本次梯度也为 0。它不是永久删除神经元；下一次迭代会重新采样掩码。

6 5. 激活函数

6.1 5.1 为什么线性层之间必须有非线性

若没有激活函数：

$$h_1 = W_1 x, \quad h_2 = W_2 h_1$$

则：

$$h_2 = W_2 W_1 x = W' x$$

无论堆叠多少层，整体仍是一次线性变换。

6.2 5.2 Sigmoid、ReLU、GELU

Sigmoid:

$$\sigma(x) = \frac{1}{1 + e^{-x}}, \quad \sigma'(x) = \sigma(x)(1 - \sigma(x))$$

输入绝对值较大时导数接近 0，深层网络中容易产生梯度消失。

ReLU:

$$\text{ReLU}(x) = \max(0, x)$$

正区间梯度为 1，计算简单；负区间梯度为 0，可能出现死亡 ReLU。

GELU:

$$\text{GELU}(x) = x\Phi(x)$$

在 0 附近平滑，梯度变化连续，但计算成本高于 ReLU。

7 6. VGG 与小卷积核

7.1 6.1 感受野

stride=1 时，每增加一层 3×3 卷积，感受野边长增加 2:

$$3 \rightarrow 5 \rightarrow 7$$

所以三个 3×3 卷积与一个 7×7 卷积具有相同的理论感受野。

7.2 6.2 参数量与表达能力

输入输出通道均为 C :

$$\text{三个 } 3 \times 3: \quad 3 \times 9C^2 = 27C^2$$

$$\text{一个 } 7 \times 7: \quad 49C^2$$

三个小卷积参数更少，而且可插入三次非线性。它们不是与单个大卷积完全等价，只是感受野相同。

8 7. ResNet 与残差连接

8.1 7.1 为什么深层普通网络会退化

普通深层网络理论表达能力更强，但实验中更深模型可能同时具有：

- 更高训练误差；
- 更高测试误差。

这不是典型过拟合，而说明更深网络更难优化。

8.2 7.2 残差学习

普通块直接学习目标映射：

$$H(x)$$

残差块改为学习：

$$F(x) = H(x) - x$$

最后：

$$H(x) = F(x) + x$$

若理想操作是保持输入不变，只需：

$$F(x) = 0$$

比让若干非线性卷积层精确学习恒等映射更容易。


8.3 7.3 它和 CNN 的关系

残差连接是一种通用连接方式，不是与 CNN 并列的替代物。ResNet 中：

- 卷积层学习新变化 $F(x)$ ；
- shortcut 传递已有特征 x ；
- 相加得到更新后的特征。

普通 CNN: $x \rightarrow \text{Conv} \rightarrow \text{ReLU} \rightarrow \text{Conv} \rightarrow \text{output}$

残差 CNN:



9 8. 多个残差块与 F_1, F_2

假设第一组有两个残差块：

$$x_1 = F_1(x_0) + x_0$$

$$x_2 = F_2(x_1) + x_1$$

因此两个 F 确实表示两次残差连接。

注意：

- x_0 是第一块的输入特征；
- x_1 是第一块输出，也是第二块输入；
- x_2 是第二块输出；
- 这里的 x 不一定是原始图像。

10 9. 为什么形状保持 $64 \times 56 \times 56$

原图经过 ResNet stem:

$$3 \times 224 \times 224 \xrightarrow{7 \times 7, S=2, 64 \text{ filters}} 64 \times 112 \times 112$$

再经过 stride=2 最大池化:

$$64 \times 112 \times 112 \rightarrow 64 \times 56 \times 56$$

进入第一组残差块后, 主分支使用:

$$3 \times 3, \quad S = 1, \quad P = 1, \quad 64 \text{ filters}$$

空间尺寸:

$$H_{\text{out}} = \frac{56 + 2 - 3}{1} + 1 = 56$$

通道数由 64 个卷积核保持为 64。因此:

$$F(x), x \in \mathbb{R}^{64 \times 56 \times 56}$$

逐元素相加后形状不变。

11 10. 通道数变化与投影捷径

阶段切换常见:

$$64 \times 56 \times 56 \rightarrow 128 \times 28 \times 28$$

11.1 10.1 主分支

使用 128 个 3×3 卷积核、stride=2:

$$F(x) \in \mathbb{R}^{128 \times 28 \times 28}$$

11.2 10.2 捷径分支

原输入不能直接相加, 因此使用:

$$1 \times 1 \text{ Conv}, \quad S = 2$$

其权重:

$$W_s \in \mathbb{R}^{128 \times 64 \times 1 \times 1}$$

得到:

$$W_s x \in \mathbb{R}^{128 \times 28 \times 28}$$

最终:

$$H(x) = F(x) + W_s x$$

11.3 10.3 1×1 卷积如何改变通道数

在每个空间位置，输入是 64 维通道向量：

$$x_{:,i,j} \in \mathbb{R}^{64}$$

每个 1×1 卷积核拥有 64 个权重，产生一个输出通道。128 个卷积核相当于：

$$\mathbb{R}^{64} \rightarrow \mathbb{R}^{128}$$

的线性映射，并在所有空间位置共享参数。

12 11. 同一层神经元与参数共享

12.1 11.1 全连接层

$$z = Wx + b$$

W 的每一行是一名神经元的完整权重。它们：

- 读取相同来源的输入；
- 使用不同权重；
- 并列计算；
- 有机会学习不同特征。

12.2 11.2 CNN 中的两个层次

1. **不同输出通道**：对应不同卷积核，应该学习不同模式。
2. **同一通道不同空间位置**：由同一卷积核重复计算，故意共享参数。

不同卷积核若完全相同：

相同参数 $\rightarrow$ 相同输出 $\rightarrow$ 相同梯度 $\rightarrow$ 相同更新

因此需要随机初始化打破对称性。

同一卷积核跨位置共享则是合理的，因为同一种边缘不应因位置变化而重新学习。

13 12. Kaiming 初始化

权重过小会导致激活逐层衰减，过大会导致激活爆炸。

ReLU 网络中常用：

$$W_{ij} \sim \mathcal{N}\left(0, \frac{2}{D_{\text{in}}}\right)$$

即：

$$\text{std}(W) = \sqrt{\frac{2}{D_{\text{in}}}}$$

对于卷积层：

$$D_{\text{in}} = C_{\text{in}} K_H K_W$$

例如 $C_{\text{in}} = 64$ 、 $K = 3$:

$$D_{\text{in}} = 64 \times 3 \times 3 = 576$$

初始化只设定起点，不会在训练过程中持续约束权重分布。

14 13. 权重衰减

14.1 13.1 更新公式

无权重衰减:

$$W_{t+1} = W_t - \eta \nabla_W L_{\text{data}}$$

加入权重衰减:

$$W_{t+1} = W_t - \eta \nabla_W L_{\text{data}} - \eta \lambda W_t$$

整理:

$$W_{t+1} = (1 - \eta \lambda) W_t - \eta \nabla_W L_{\text{data}}$$

每次更新都把原权重乘上略小于 1 的系数，因此权重被轻轻拉向 0。

14.2 13.2 L2 正则化视角

$$L_{\text{total}} = L_{\text{data}} + \frac{\lambda}{2} \|W\|_2^2$$

梯度:

$$\nabla_W L_{\text{total}} = \nabla_W L_{\text{data}} + \lambda W$$

它要求模型在降低预测误差的同时，避免使用不必要的极端参数。

14.3 13.3 AdamW

SGD 中 L2 正则与直接权重衰减基本等价；在 Adam 中，若把 λW 混入梯度，它也会被自适应缩放。

AdamW 将两者解耦:

$$W_{t+1} = (1 - \eta \lambda) W_t - \eta \text{AdamUpdate}(\nabla L)$$

15 14. 权重衰减与重要特征

权重衰减确实对所有被选中的权重施加收缩，包括重要特征相关参数。但它不是唯一力量。

对单个权重:

$$w_{\text{new}} = w - \eta \frac{\partial L_{\text{data}}}{\partial w} - \eta \lambda w$$

- 数据梯度：保护能显著降低损失的参数。
- 衰减项：压缩缺少数据证据支持的参数。

以猫分类为例：

- 耳朵、毛发、轮廓若被削弱，会使大量样本损失上升，梯度会把相关参数推回来；
- 草地背景、水印等偶然关联被削弱后，任务损失变化小，难以抵抗衰减。

因此合适的权重衰减更像提出要求：

想保留大权重，就必须证明它确实持续有助于降低任务损失。

但若 λ 过大，重要特征也会被压制，表现为训练准确率都无法提高，即欠拟合。

15.1 14.1 权重大小不等于特征重要性

真实 CNN 中“耳朵”通常由多层、多通道共同表示，不对应单个权重。某个特征对输出的贡献还取决于：

$$w \cdot x$$

以及后续层、归一化、非线性和其他通道的组合。不能只看一个权重绝对值判断语义重要性。

16 15. 数据增强

数据增强在训练时对图片施加标签保持不变的变换：

$$y(T(x)) = y(x)$$

常见方法：

- 水平翻转；
- 随机裁剪与缩放；
- 亮度、对比度、饱和度扰动；
- Cutout。

它让模型看到同一语义的不同版本，降低对固定位置、背景和光照的依赖。

增强必须符合任务不变性：文字识别不适合随意水平翻转；若颜色决定类别，Color Jitter 也不能过强。

17 16. 迁移学习

预训练 CNN 的浅层通常学习通用边缘和纹理，深层逐渐变得任务特定。

17.1 16.1 数据少、领域相似

冻结骨干：

$$\theta_{\text{backbone}} \text{ fixed}$$

只训练新的分类层：

$$W_C$$

17.2 16.2 数据较多、领域相似

从预训练权重初始化，微调整个模型。

17.3 16.3 领域差异大

优先寻找更匹配领域的预训练模型，并通过验证实验比较从头训练与微调。

18 17. 训练调试

18.1 17.1 先过拟合一个小样本

若有足够容量的模型连一个样本都无法记住，应优先排查：

- 标签错位；
- loss 使用错误；
- 没有 backward()；
- 没有 optimizer.step()；
- 参数被冻结；
- 学习率异常；
- 增强过强；
- train/eval 状态错误。

18.2 17.2 训练/验证曲线

现象	可能问题
训练与验证都差	欠拟合、训练失败或学习率不合适
训练很好、验证差	过拟合，需增强正则化或数据
两者一起改善	可继续训练
增加权重衰减后训练也明显变差	正则化过强

18.3 17.3 随机搜索

若只有一个超参数真正重要，网格搜索会把大量实验浪费在不重要维度的重复组合上。随机搜索能更充分覆盖每个维度，通常是更好的默认策略。

19 18. 本讲最重要的闭环

卷积层生成特征

- 归一化稳定特征尺度
- 激活函数引入非线性
- 小卷积堆叠扩大感受野
- 残差连接保留输入并改善深层优化
- Kaiming 初始化保证训练起点稳定
- Dropout、权重衰减和数据增强抑制过拟合
- 训练集统计量统一所有阶段的输入定义
- 迁移学习降低数据与计算需求
- 小样本过拟合与验证曲线完成训练调试

20 19. 常见误区

1. 归一化会永久限制模型表达。 - 后面的 γ, β 可重新缩放和平移。
2. 训练集均值和标准差是模型权重。 - 它们是预处理统计量，不通过反向传播学习。
3. 验证集应计算自己的统计量。 - 应固定使用训练集统计量，避免改变输入定义和数据泄漏。
4. Dropout 测试时也随机丢弃。 - 标准推理时关闭 Dropout，使用完整网络。
5. 残差连接替代卷积。 - 它改变连接方式，主分支仍由卷积学习 $F(x)$ 。
6. 一个 F 表示一层卷积。 - F 通常代表一个残差块主分支中的全部运算。

7. 两个 F 属于同一个残差相加。 - 通常对应两个连续残差块和两次相加。
8. 残差块中的 x 永远是原图。 - x 是当前块输入特征。
9. 通道数由输入通道决定。 - 输出通道数由卷积核数量决定。
10. 不同卷积核共享参数。 - 参数共享发生在同一卷积核的不同空间位置。
11. 权重衰减会自动识别背景特征。 - 它统一收缩参数，语义重要性由任务梯度决定。
12. 权重越大就说明特征越重要。 - 真实贡献取决于激活及整个网络组合。

21 20. 自测问题

1. 为什么归一化常放在线性层后？
2. LayerNorm 与 BatchNorm 的统计范围有什么区别？
3. 为什么验证和测试必须使用训练集均值与标准差？
4. 推导 inverted dropout 为什么能保持激活期望不变。
5. 三个 3×3 卷积为什么具有 7×7 感受野？
6. 为什么普通深层网络训练误差更高不能解释为过拟合？
7. $H(x) = F(x) + x$ 中， x 具体指什么？
8. 两个连续残差块如何写成公式？
9. 为什么第一组残差块保持 $64 \times 56 \times 56$ ？
10. 1×1 卷积如何将通道数从 64 变为 128？
11. CNN 中不同卷积核与同一卷积核不同位置有什么区别？
12. Kaiming 初始化中的 D_{in} 对卷积层如何计算？
13. 权重衰减为何会把权重往 0 拉？
14. 为什么重要特征通常能抵抗适度权重衰减？
15. 如何通过训练/验证曲线判断正则化是否过强？

22 一句话收束

CNN 架构设计并不只是把卷积层堆得更深，而是要同时管理信号尺度、非线性、信息保留和模型复杂度：归一化与初始化让网络稳定，残差连接让深层网络可优化，Dropout、权重衰减和数据增强让模型不过度记忆训练集，最终再通过一致的数据预处理、迁移学习和系统调试把整个训练闭环真正跑通。